

République Algérienne Démocratique et
Populaire

Ministère de l'Enseignement Supérieur et de la
Recherche Scientifique

Université de Béjaïa

Faculté des Sciences Exactes – Département d'Informatique



جامعة بجاية
Tasdawit n Bgayet
Université de Béjaïa

Projet COMPILATION

(Mini compilateur)

Sujet :

Compilateur mini en java pour langage python (if/else)

Réalisé par : SALIM MANCER

Table des matières

| | | |
|----------|-----------------------------------|----------|
| 1 | Introduction | 2 |
| 2 | Présentation du Lexer | 3 |
| 2.1 | Méthode utilisée | 3 |
| 2.2 | Fonctionnement général | 3 |
| 2.3 | Exemple de tokenisation | 3 |
| 3 | Présentation du Parser | 4 |
| 3.1 | Méthode utilisée | 4 |
| 3.2 | Grammaire utilisée | 4 |
| 3.3 | Fonctionnement général | 4 |
| 4 | Conclusion et Perspectives | 5 |

Chapitre 1

Introduction

L'objectif de ce projet est de concevoir un compilateur simple pour le langage Python en Java, comprenant un analyseur lexical (**lexer**) et un analyseur syntaxique (**parser**). Le projet illustre les concepts fondamentaux de la compilation, notamment la reconnaissance lexicale et l'analyse syntaxique basée sur une grammaire.

Chapitre 2

Présentation du Lexer

2.1 Méthode utilisée

Le lexer a été implémenté à la **main**, sans utiliser de générateur de lexer comme JFlex. La méthode consiste à parcourir le code source caractère par caractère et à construire des **tokens** en fonction du type rencontré : mots-clés, identifiants, nombres, opérateurs, chaînes de caractères, etc.

2.2 Fonctionnement général

- Ignorer les espaces et tabulations grâce à la méthode `ignorerespaces()`.
- Identifier les mots-clés et identifiants avec `avancer_caractere()` et `chiffre_nombre()`.
- Détecter les nombres avec `avancernumber()`.
- Reconnaître les opérateurs (`=`, `==`, `+`, `+=`, `-`, `-=`, `*`, `*=`, `/`, `/=`, `%`) via `avanceroperateur()`.
- Gérer les chaînes de caractères et les retours à la ligne pour l'indentation (tokens `INDENT`, `DEDENT`, `NEWLINE`).

2.3 Exemple de tokenisation

Le lexer transforme le code source Python suivant :

```
[language=Python] if a == 10 : print("Bonjour") else : a = a + 1
```

en une liste de tokens :

```
IF, IDENTIFIER(a), EQEQ, NUMBER(10), COLON, NEWLINE, INDENT, PRINT,
LPAREN, CHAINE("Bonjour"), RPAREN, NEWLINE, DEDENT, ELSE, COLON, NEW-
LINE, INDENT, IDENTIFIER(a), EQUALS, IDENTIFIER(a), PLUS, NUMBER(1),
NEWLINE, DEDENT, EOF
```

Chapitre 3

Présentation du Parser

3.1 Méthode utilisée

Le parser a été conçu selon une approche **réursive descendante**, ce qui signifie que chaque règle de la grammaire est traduite en méthode Java réursive.

3.2 Grammaire utilisée

La grammaire factorisée et sans récursion à gauche est la suivante :

- $\text{PROGRAM} \rightarrow \text{STATEMENT_LIST EOF}$
- $\text{STATEMENT_LIST} \rightarrow \text{STATEMENT STATEMENT_LIST1}$
- $\text{STATEMENT_LIST1} \rightarrow \text{STATEMENT STATEMENT_LIST1} \mid \epsilon$
- $\text{STATEMENT} \rightarrow \text{SIMPLE_STMT} \mid \text{COMPOUND_STMT}$
- $\text{SIMPLE_STMT} \rightarrow \text{ASSIGN} \mid \text{PRINT_CALL}$
- $\text{COMPOUND_STMT} \rightarrow \text{IF_STMT}$
- $\text{IF_STMT} \rightarrow \text{IF EXPR COLON BLOCK IF_TAIL}$
- $\text{IF_TAIL} \rightarrow \text{ELIF EXPR COLON BLOCK IF_TAIL} \mid \text{ELSE COLON BLOCK} \mid \epsilon$
- $\text{BLOCK} \rightarrow \text{NEWLINE INDENT STATEMENT_LIST DEDENT}$
- $\text{EXPR} \rightarrow \text{OR_EXPR}$
- $\text{OR_EXPR} \rightarrow \text{AND_EXPR OR_EXPR1}$
- $\text{OR_EXPR1} \rightarrow \text{OR AND_EXPR OR_EXPR1} \mid \epsilon$
- $\text{AND_EXPR} \rightarrow \text{NOT_EXPR AND_EXPR1}$
- $\text{AND_EXPR1} \rightarrow \text{AND NOT_EXPR AND_EXPR1} \mid \epsilon$
- $\text{NOT_EXPR} \rightarrow \text{NOT NOT_EXPR} \mid \text{COMP_EXPR}$
- $\text{COMP_EXPR} \rightarrow \text{FACTOR} (\text{COMP_OP FACTOR})^*$
- $\text{FACTOR} \rightarrow \text{NUMBER} \mid \text{TRUE} \mid \text{FALSE} \mid \text{IDENTIFIER} \mid \text{CHAINE} \mid \text{LPAREN EXPR RPAREN}$

3.3 Fonctionnement général

Le parser lit la liste de tokens générée par le lexer et :

- Vérifie que les instructions simples (**ASSIGN**, **PRINT**) sont syntaxiquement correctes.
- Gère les blocs d'instructions indentés avec **INDENT** et **DEDENT**.
- Analyse les expressions logiques et arithmétiques récursivement.
- Vérifie la cohérence des structures conditionnelles (**if**, **elif**, **else**).

Chapitre 4

Conclusion et Perspectives

Le projet a permis de mettre en pratique les concepts fondamentaux de la compilation :

- Conception d'un lexer à la main pour Python.
- Implémentation d'un parser récursif descendant.
- Gestion des indentations et des structures conditionnelles.

Des perspectives d'amélioration comprennent :

- Support complet des boucles (`for`, `while`) et des exceptions (`try/except`).
- Génération d'un arbre syntaxique abstrait (AST) pour des optimisations ultérieures.
- Extension pour d'autres structures Python (fonctions, classes, imports...).